

Informe del proyecto: MODULE-8-PYTHON-DATA-LIFECYCLE

Autor: Miguel Encinas Gimenez

1. Descripción general del proyecto

El repositorio MODULE-8-PYTHON-DATA-LIFECYCLE corresponde al proyecto final del Módulo 8 del programa Data & Analytics V3 de ThePower. El proyecto tiene como objetivo aplicar Python al ciclo de vida completo de un conjunto de datos real, desde la carga y limpieza inicial hasta la generación de visualizaciones y una primera aproximación al modelado predictivo.

El conjunto de datos se corresponde con una campaña de marketing bancario. A partir de los datos disponibles, se estudiaron las características de los clientes, qué variables podían estar relacionadas con la contratación del producto, y el potencial del conjunto de datos como predictor de la variable objetivo.

El trabajo se organizó de forma secuencial en diferentes scripts de Python, cada uno de ellos asociado a una fase concreta del proceso:

1. Limpieza y transformación de la tabla principal.
2. Limpieza y transformación de una tabla auxiliar de clientes.
3. Unión de ambas fuentes de datos.
4. Visualización y análisis gráfico.
5. Primera aproximación a la predicción de la variable objetivo.

2. Estructura del repositorio

El repositorio se organiza en tres grandes bloques:

2.1. Notebooks (py)

Esta carpeta contiene los scripts de Python utilizados durante el proyecto:

- **01_EDA_bank_additional.py**: análisis, limpieza y transformación de la tabla principal.
- **02_EDA_customer_details.py**: limpieza del archivo auxiliar 'customer-details.xlsx'.
- **03_merge_dataframes.py**: unión de la tabla principal y auxiliar mediante la columna 'Client ID'.
- **04_data_visualizations.py**: generación de visualizaciones exploratorias.
- **05_objective_variable_prediction.py**: prueba de modelos predictivos para la variable objetivo.

2.2. Project Data

Esta carpeta se divide en dos subcarpetas:

- **Raw Data**: contiene los archivos originales del proyecto ([bank-additional.csv](#) y [customer-details.xlsx](#))
- **Curated data**: contiene los archivos resultantes tras la limpieza, transformación y unión de datos ([01_EDA_bank_additional.csv](#), [01_descriptive_statistics_main.csv](#), [02_EDA_customer_details.csv](#), [02_descriptive_statistics_details.csv](#), [03_merge_dataframes.csv](#) y [03_DF_Final_Excel.xlsx](#)).

2.3. Visualizations

Esta carpeta contiene las visualizaciones generadas durante el análisis. Se organiza en diferentes bloques, incluyendo: Distribución general de clientes, Distribución de la variable objetivo según diferentes variables y Evolución temporal a lo largo de los años.

3. Descripción de los datos

El proyecto utiliza dos fuentes principales de información:

3.1. Tabla principal: bank-additional.csv

La tabla principal contiene información relacionada con clientes incluidos en la campaña de marketing. Incluye variables como edad, trabajo, nivel educativo, préstamos, método de contacto, número de contactos realizados durante la campaña o resultado de campañas anteriores. Además, contiene indicadores económicos (IPC, confianza del consumidor, etc.) y la variable objetivo (si el cliente se suscribió o no al producto/servicio, inicialmente catalogada como 'y'). Durante el análisis, se hace evidente que la variable objetivo está desbalanceada: la mayoría de clientes no se suscribe al producto/servicio, lo cual es relevante para la interpretación de los gráficos y el modelado predictivo que se elaboran posteriormente.

3.2. Tabla auxiliar: customer-details.xlsx

La tabla auxiliar contiene información adicional de clientes. Está dividida en tres hojas correspondientes a los años 2012, 2013 y 2014. Cada hoja se carga de forma independiente, y posteriormente se concatenan todas en un único *dataframe*. Esta tabla se usa para complementar la información de la tabla principal antes de realizar las visualizaciones y el modelado.

4. Procedimientos realizados

4.1. Carga inicial e inspección de los datos

El primer paso consistió en cargar los archivos con pandas y revisar su estructura básica mediante métodos como: `head()`, `info()`, `isnull().sum()`, `isna().sum()`, `describe()` o `value_counts()`.

Esta revisión permitió identificar columnas con valores nulos, variables con formatos incorrectos, columnas poco útiles y variables que requerían transformación antes del análisis.

4.2. Tratamiento de valores nulos

El tratamiento de valores nulos se realizó de forma razonada. No se aplicó una única estrategia general, sino que se evaluó cada columna de manera individual en función del contexto del conjunto de datos. Algunas decisiones destacadas fueron:

- Sustituir valores nulos por *Not informed* en variables donde se consideró importante conservar las filas, como edad, trabajo o educación.
- Sustituir valores nulos por la categoría mayoritaria en casos puntuales, como el estado civil, donde la categoría más frecuente era claramente predominante.
- Sustituir valores nulos de variables numéricas continuas por la media, siempre y cuando el número de valores nulos fuera bajo y la distribución lo permitía.
- Eliminar columnas cuando se consideró que aportaban poca información o presentaban un número demasiado alto de nulos: 'default', 'euribor3m', 'latitude', 'longitude' y 'nr.employed'.
- Eliminar las filas sin fecha de contacto, al tratarse de una información relevante para el análisis.

4.3. Transformación de variables

Se realizaron varias transformaciones orientadas a mejorar la calidad e interpretabilidad del conjunto de datos:

- Conversión de variables numéricas almacenadas como texto.
- Sustitución de separadores decimales y eliminación de comillas en columnas numéricas.
- Estandarización de formatos de texto.
- Extracción de mes y año a partir de columnas de fecha.

- Traducción del valor de los meses a distintos formatos.
- Renombrado de columnas para mejorar su legibilidad.
- Reordenación de columnas de cara a la visualización y el análisis posterior.

4.4. Creación de nuevas variables categóricas

Una parte importante del proyecto consistió en transformar variables numéricas o muy desagregadas en variables categóricas más útiles para el análisis exploratorio. Se crearon variables como:

- **'Age group'**: clasificación de clientes por rango de edad.
- **'Job group'**: agrupación de tipos de trabajo en categorías más generales.
- **'Educational group'**: simplificación de niveles educativos.
- **'Last call (range)'**: clasificación de la duración de la última llamada.
- **'Contacts during campaign (range)'**: rango del número de contactos durante la campaña.
- **'Days from last call (range)'**: rango de los días desde la última llamada.
- **'IPC (range)'**: clasificación de niveles del IPC.
- **'Confidence level (range)'**: clasificación de la confianza del consumidor.
- **'Employment variation (range)'**: clasificación de la variación del empleo.
- **'Annual income (range)'**: agrupación de ingresos anuales.
- **'Web visit freq. (per month)'**: clasificación de frecuencia mensual de visitas a nuestra web.

4.5. Generación de estadísticas descriptivas

Antes de eliminar o agrupar determinadas variables numéricas, se guardaron estadísticas descriptivas en archivos .csv independientes, lo que permite conservar información básica sobre las variables originales. Los archivos generados fueron: **01_descriptive_statistics_main.csv** y **02_descriptive_statistics_details.csv**.

4.6. Unión de fuentes de datos

Tras limpiar la tabla principal y la tabla auxiliar, ambas se unieron a través de la columna **Client ID**. El resultado fue un *dataframe* final compuesto por los datos de ambas tablas, combinando información acerca de la campaña, factores macroeconómicos, y varios factores socioeconómicos y de comportamiento de los clientes.

La unión se realizó mediante un **merge()** de tipo 'inner', por lo que el dataset final conserva únicamente los registros con coincidencia en ambas tablas; al ser el valor de Client ID único para cada cliente, la unión se realizó de manera correcta.

4.7. Visualización de datos

El análisis visual se organizó en varios bloques:

Distribución de clientes

En primer lugar, se analizaron las distribuciones generales de los clientes. Este bloque permite responder preguntas como:

- Qué grupos de edad son más frecuentes.
- Qué perfiles profesionales son más frecuentes.
- Qué proporción de clientes tiene hipoteca u otros préstamos.
- Cómo se distribuyen los clientes según campañas anteriores.

Relación con la variable objetivo

Después, se estudió cómo varía la proporción de aceptación de la oferta según diferentes variables. Este bloque resultó de especial importancia para extraer conclusiones de negocio, ya que permite identificar factores o situaciones asociadas a mayor o menor probabilidad de suscripción.

Entre los factores estudiados se incluyen: edad, trabajo, estado civil, préstamos, campañas previas, contactos durante la campaña, indicadores económicos, ingresos, composición del hogar, etc.

Evolución temporal

Por último, se estudiaron algunos de patrones temporales a través de los años, en función del año en el que fue contactado el cliente por primera vez. Este análisis permite observar si la aceptación de la oferta cambia con el tiempo. A pesar de haber realizado solamente dos gráficas de este estilo, como se demuestra en la segunda gráfica, la técnica y el bloque de código son extrapolables a la variable que se quiera estudiar, para ver cómo evoluciona la probabilidad de contratar el producto en función de diversos factores.

5. Aproximación predictiva

La última fase del proyecto consistió en explorar si el conjunto de datos tratados podía utilizarse para predecir la variable objetivo. El flujo de trabajo seguido para ello fue el siguiente:

1. Selección de variables.
2. Eliminación de columnas redundantes.
3. Conversión de la variable objetivo a formato binario.
4. División de datos en entrenamiento y testeo.
5. Escalado de variables numéricas con *StandardScaler*.
6. Codificación de variables categóricas con *OneHotEncoder*.
7. Entrenamiento de una regresión logística.
8. Entrenamiento con un árbol de decisión.
9. Evaluación y comparación de *accuracy*, *precision* y matriz de confusión para ambos métodos.

La regresión logística obtiene una *accuracy* aproximada de 0.85, pero una *precision* de 0.43, lo que indica problemas para identificar correctamente los casos positivos. El árbol de decisión mejora la *precision* hasta aproximadamente 0.60 y la *accuracy* hasta 0.90. Estos resultados sugieren que el conjunto de datos contiene señales predictivas, dejando un margen de mejora mediante el entrenamiento con otros métodos, así como el refinamiento de los parámetros de los algoritmos.

6. Conclusiones principales

El proyecto cubre de forma bastante completa las fases principales del ciclo de vida del dato:

- Carga de datos desde archivos CSV y Excel.
- Limpieza y tratamiento de valores faltantes.
- Transformación de variables.
- Creación de nuevas columnas analíticas.
- Unión de diferentes fuentes de datos.
- Generación de conjuntos de datos limpios y ordenados.
- Creación de visualizaciones.
- Primera aproximación a un modelado predictivo.

Desde el punto de vista analítico, el proyecto permite estudiar qué características parecen más relacionadas con la suscripción a un producto/servicio. Además, introduce un método predictivo que permite conectar el análisis descriptivo con una posible aplicación real: anticipar qué clientes tienen mayor probabilidad de aceptar la oferta. Desde el punto de vista técnico, el proyecto ha afianzado el manejo de *pandas*, *NumPy*, *seaborn*, *matplotlib* y *scikit-learn*, así como la comprensión de conceptos importantes en relación a la limpieza de datos, la transformación de variables, y la elaboración de gráficas para visualizar los datos.